



Sviluppo di un Simulatore Predittivo per la FIFA World Cup 2026

*Machine Learning, Ensemble Learning e Simulazione Monte Carlo
per la modellazione probabilistica del calcio internazionale*



Angelo Lapacciana

Metodi Matematici per l'Intelligenza Artificiale — Università degli Studi di Bari

Luglio 2026

Agenda della Presentazione

01



Contesto e Sfida Analitica

Perché il calcio richiede un approccio probabilistico?

02



Dati e Data Leakage

Dataset storici e allineamento temporale corretto

03



Feature Engineering

Le tre variabili che alimentano il modello

04



Architettura del Modello

Random Forest, XGBoost, LightGBM e Soft Ensemble

05



Simulazione Monte Carlo

Dal singolo match all'intero torneo

06



Deploy, Risultati e Sviluppi Futuri

L'app Streamlit, l'Oracolo e i prossimi passi

Contesto e Sfida Analitica

- **Natura "Low-Scoring"**

Essendo uno sport caratterizzato da poche reti, la legge dei grandi numeri non riesce a compensare l'alta varianza statistica del match.

- **Limiti dell'approccio deterministico**

I singoli episodi fortuiti assumono un peso sproporzionato sul risultato finale, rendendo la ricerca di un esito certo strutturalmente inaffidabile.

- **La soluzione probabilistica**

L'obiettivo è misurare l'incertezza, traducendo l'imprevedibilità in distribuzioni di probabilità.

48

Squadre partecipanti (dalle 32 del 2022)

12

Gironi da 4 squadre ciascuno

3

Nazioni ospitanti: USA · Messico · Canada

I Dati e il Problema del Data Leakage

**results.csv**

40.000+ partite ufficiali e amichevoli, dal 1900 ad oggi. Squadre, punteggi, torneo, sede, campo neutro.

**elo_ratings_wc2026.csv**

Snapshot annuali (31 dicembre) del rating Elo, dal 1872 al 2026: rank, punteggio, confederazione.

Frequenza giornaliera (partite) vs annuale (snapshot Elo): un merge diretto “sbircia” nel futuro.

✗ Merge Diretto (Data Leakage)



✓ merge_asof(direction='backward')



Fattore campo: il flag “neutral” viene sovrascritto dinamicamente per le partite di USA, Messico e Canada, per non falsare il vantaggio casalingo reale.

Feature Engineering: Tre Variabili, Massima Informazione



elo_diff

Differenza di rating Elo (casa – trasferta). La feature più potente e più correlata con l'esito.



goals_diff_last_3


Media gol nelle ultime 3 partite (rolling window): cattura la forma immediata, dove l'Elo è troppo “lento”.



neutral

Fattore campo: flag binario (0/1) che segnala il vantaggio casalingo.


$X = [\text{elo_diff} , \text{goals_diff_last_3} , \text{neutral}]$



Dati reali dal report: probabilità di vittoria empirica per bin di ΔElo — relazione logistica.


Analisi Esplorativa dei Dati: Ulteriori Evidenze

Evoluzione Storica del Rating Elo




Le fluttuazioni riflettono cicli storici (mondiali vinti, generazioni d'oro, declini tecnici) impossibili da cogliere con un rating statico.

Distribuzione dei Gol: Casa vs Trasferta



Il calcio è "low-scoring" (1-2 gol a partita); le squadre di casa mostrano una varianza di gol maggiore.

Matrice di Correlazione tra le Variabili




elo_diff è la feature più correlata con l'esito; nessuna correlazione spuria tra le variabili.

L'EDA non ha guidato la scoperta delle feature: le ha validate empiricamente, a conferma delle ipotesi domain-driven formulate a priori.

Architettura del Modello Predittivo

Il problema dello sbilanciamento delle classi



Random Forest

Bagging + selezione casuale delle feature.



XGBoost

Boosting sequenziale: corregge i residui albero dopo albero.



LightGBM

Boosting leaf-wise: aggressivo, alta capacità di apprendimento.

Strategia di addestramento: TimeSeriesSplit (n_splits=3) · RandomizedSearchCV (n_iter=50) · metrica: Log Loss · holdout dal 2024-01-01

Migliori Iperparametri (RandomizedSearchCV)



Random Forest

max_depth = 3
max_features = 3
min_samples_split = 10
min_samples_leaf = 1
n_estimators = 200



XGBoost

max_depth = 2
learning_rate = 0.01
n_estimators = 300
subsample = 0.6
colsample_bytree = 1.0
min_child_weight = 10




LightGBM

num_leaves = 7
learning_rate = 0.01
n_estimators = 200
min_child_samples = 20


Il Soft Ensemble: Stabilità sopra la Performance Singola

Media aritmetica delle probabilità (Probability Averaging) invece dell'hard voting, che scarterebbe l'incertezza marginale.

Log Loss (lower is better)




Accuracy (higher is better)



L'Ensemble non vince su nessuna singola metrica, ma è il compromesso più stabile: riduce le previsioni troppo confidenti e alimenta il Monte Carlo con probabilità affidabili (Garbage-In, Garbage-Out).

Tempi di Addestramento e Metriche per Classe

Tempi di Addestramento e Robustezza Hardware




- XGBoost è il più veloce: implementazione C++ ottimizzata e parallelizzazione nativa sugli 8 core.
- LightGBM è il più lento: la crescita leaf-wise richiede calcoli meno parallelizzabili.

Le metriche predittive restano identiche su hardware diverso ($\Delta < 0,01\%$): si addestra una volta su una macchina potente e si carica ovunque per l'inferenza.

Precision, Recall e F1-Score

Ensemble (per classe)	Precision	Recall	F1-Score
Vittoria Casa	0.56	0.62	0.59
Vittoria Trasferta	0.45	0.52	0.48
Pareggio	0.22	0.16	0.19

Recall sul Pareggio per Modello: un limite strutturale



Anche con il bilanciamento delle classi, il recall sui pareggi resta al basso in tutti i modelli: si intercetta solo 1 pareggio reale su 5-6.

Il Motore di Simulazione



1 Stato “Live” singoli match

Rolling window (ultime 3 gare) per la forma;
copia isolata dell'Elo.



2 Risorse e Pipeline

Modelli deserializzati una sola volta (joblib);
pipeline modulare: match → Elo → gironi →
tabellone.



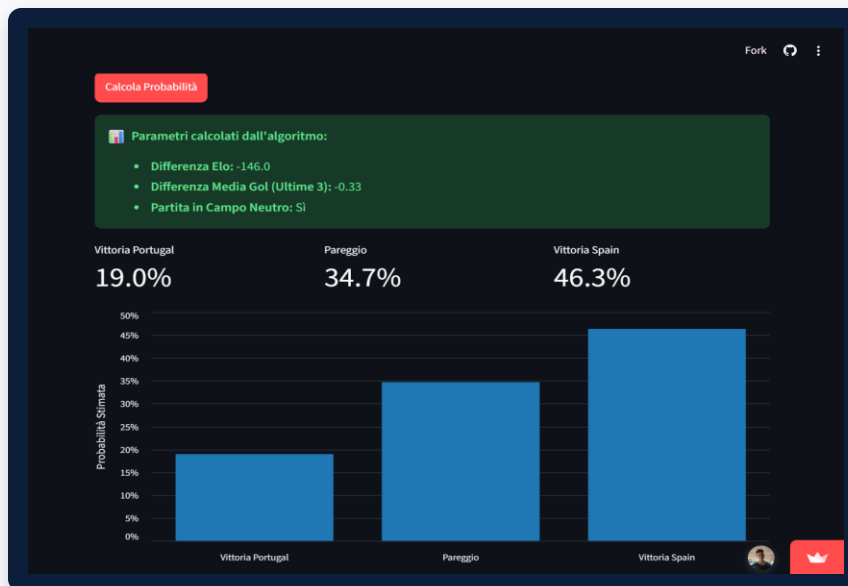
3 Rumore e Fattore Campo

Elo perturbato $\sim N(\text{elo_base}, \sigma=75)$;
vantaggio casalingo gestito dinamicamente.




4 K-Factor Dinamico

K=30 in fase a gironi, K=45 nei knockout.




Fase a gironi



Eliminazione diretta

Dal Singolo Match al Tabellone del Torneo



Fase a Gironi e Spareggio

12 gironi ufficiali; 6 match ciascuno (3-1-0 punti). Il modello stima solo 1-X-2, non i gol.



Qualificazione e Ripescaggio

Si qualificano le prime due di ogni girone (24 squadre). Le terze classificate vengono riordinate per punti ed Elo.



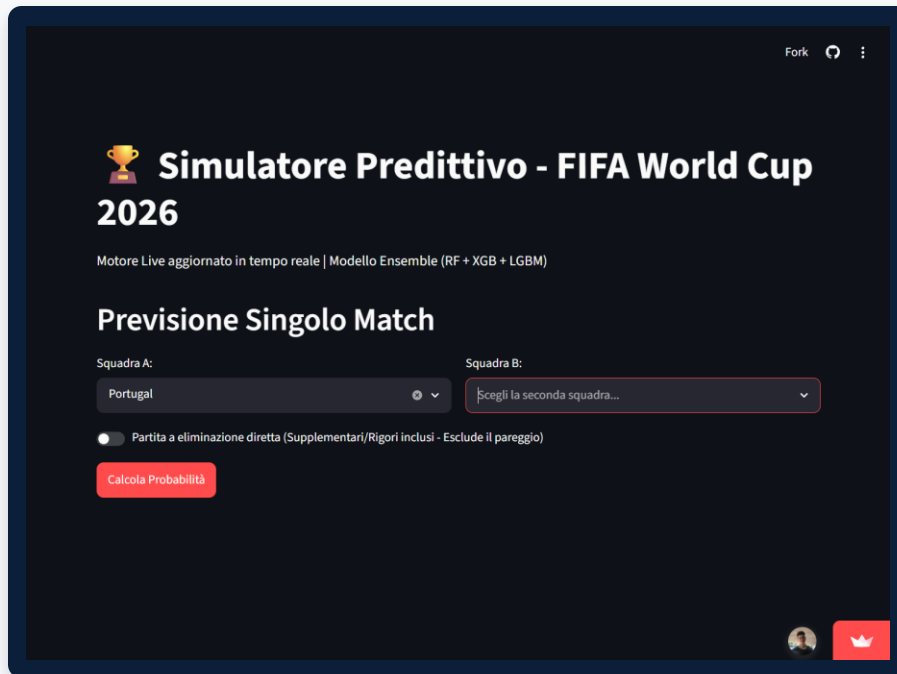
Costruzione del Tabellone

Accoppiamento in 3 fasi: terze ripescate ↔ prime, prime rimanenti ↔ seconde, seconde ↔ seconde, con fallback logico.

Da qui, solo eliminazione diretta: *gioca_turno_semplice* dimezza le squadre ad ogni turno (sedicesimi, ottavi, quarti, semifinali, finale) attivando K=45 e l'esclusione del pareggio a ogni chiamata.

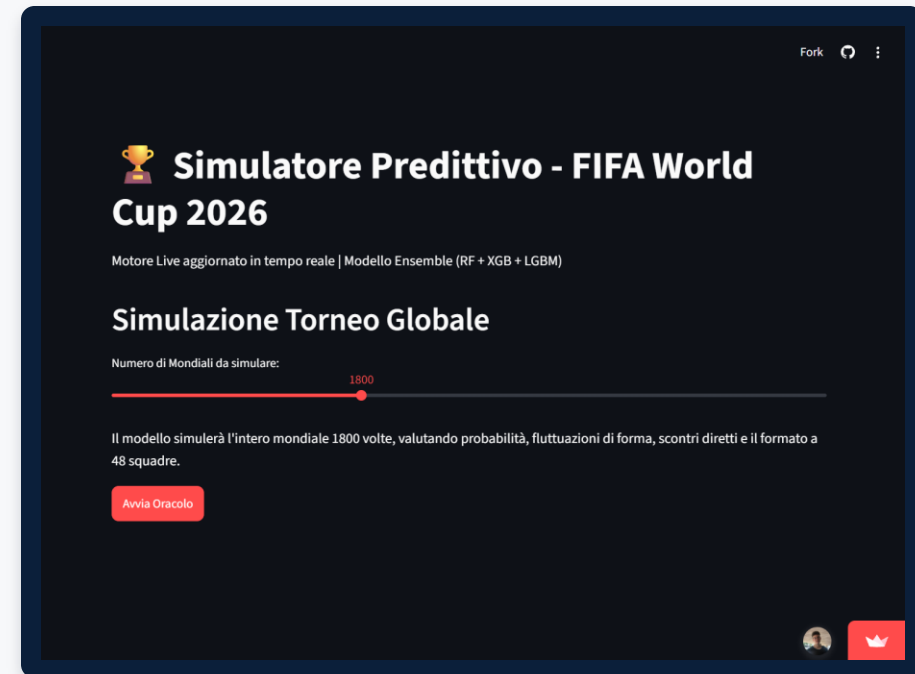
Implementazione Software e Deploy

Streamlit + **config_mondiale.json** (host nations, gironi, Elo live, storico partite) + **caching** (@st.cache_resource per i modelli, @st.cache_data per i dati) per un'app fluida ad ogni interazione.



Modulo 1 — Previsore Singolo Match


Inferenza deterministica: quote per un singolo incontro, con toggle per la fase a eliminazione diretta.




Modulo 2 — Simulazione Globale

Slider per N iterazioni (100–5.000), progress bar in tempo reale, classifica Top 15 con scala viridis.

Risultati della Simulazione Globale



N = 100 — instabile



N = 5.000 — convergenza

Con poche iterazioni la classifica oscilla (Francia, Spagna, Argentina si alternano al vertice).

Con N=5.000, la Legge dei Grandi Numeri fa convergere le frequenze verso il valore atteso.

1° Spagna
2165 Elo

2° Argentina
2113 Elo

3° Francia
2081 Elo

Top 3 favorite

Limiti dell'Architettura Attuale



Nessun risultato esatto

Il modello stima solo 1-X-2, non i gol: la differenza reti nei gironi richiede un criterio di spareggio semplificato (Elo).



Assenza di micro-dati

Infortuni, squalifiche, cambio allenatore e stato dello spogliatoio non sono catturati dal modello.



Inerzia del rating Elo

L'Elo si aggiorna lentamente: può sottovalutare una generazione emergente o sopravvalutare un declino in corso.



Fattori logistici e ambientali

Viaggi, fusi orari e clima in USA, Messico e Canada influenzano le prestazioni ma non sono modellati.

Conclusioni e Sviluppi Futuri

Un sistema end-to-end: dati storici → ensemble di Machine Learning → simulazione Monte Carlo → applicazione web interattiva.



Modello di Poisson

Stima il punteggio esatto e risolve i criteri di spareggio nei gironi



Parallelizzazione CPU multi-core

N=5.000 richiede ore di calcolo sequenziale:
il calcolo parallelo abbatterebbe
drasticamente i tempi



Automazione via API

Pipeline ETL per aggiornare Elo e risultati
in tempo reale, eliminando l'inserimento
manuale

La matematica ha fatto il suo corso. La domanda ora è: voi ci scommettereste?

Grazie per l'attenzione!